

# Dados Solar

Author <sup>a</sup>

---

## Abstract

In this paper,

*Keywords:* text ...

---

## 1. Introdução

text

## 2. Dados

Considere que a potência gerada por placas fotovoltaicas limpas, denotada por  $W$ , sejam monitoradas por  $n$  dias,  $n \geq 1$ . Suponha que para o  $j$ -ésimo dia sejam feitas  $(k_j + 1)$  medições das potências geradas, para  $j = 1, \dots, n$ . Assim,  $W_{ij}$  é a potência gerada no  $i$ -ésimo instante de tempo do dia  $j$ , para  $i = 0, \dots, k_j$  e  $j = 1, \dots, n$ . Assuma como instante inicial de medição do dia  $j$ ,  $i = 0$ , o horário em que a primeira medida de potência é gerada,  $W_{0j} > 0$ . A partir do instante da primeira medição, registramos as potências geradas em intervalos de  $h = 10$  minutos, até o instante  $i = k_j$ , onde  $k_j$  é o último horário de registro antes da placa deixar de gerar potência,  $W_{(k_j+1),j} = 0$ .

Como ilustração dos dados gerados, a Figura 1 mostra as potências geradas nos dias 1 e 2 de realização do experimento. No dia 1, a primeira medição foi feita as 5 horas e 29 minutos e a última medição foi feita as 17 horas e 39 minutos, totalizando  $k_1 = 76$  medições. Para o dia 2, a primeira medição foi feita as 5 horas e 29 minutos e a última medição foi feita as 17 horas e 49 minutos, totalizando  $k_2 = 78$  medições. No total, o experimento foi realizado durante  $n = 21$  dias (três semanas).




Figure 1: Potências geradas nos dias 1 e 2.

## 3. Modelos

Como podemos observar na Figura 1, as potências geradas apresentam um comportamento um tanto instável ao longo tempo. Isto ocorre devido a fatores ambientais, tais como, temperatura, irradiação, quantidade de sujeiras nas placas, entre outras.

Com o objetivo de obter uma descrição mais estável das potências geradas, considere  $X_{ij}$  a potência registrada de maneira acumulada até o  $i$ -ésimo instante de tempo do dia  $j$ , para  $i = 0, \dots, k_j$  e  $j = 1, \dots, n$ . Isto é,

$$X_{0j} = W_{0j} \quad \text{e} \quad X_{ij} = \sum_{i'=0}^i W_{i'j},$$

para  $i = 0, 1, \dots, k_k$  e  $j = 1, \dots, n$

A Figura 2 mostra os gráficos das potências registradas nos dias 1 e 2, de maneira acumulada. Note que, utilizando os valores acumulados, obtemos um comportamento mais estável dos dados. Além disso, a maneira

como os dados se comportam ao longo do tempo sugere algum tipo de modelo matemático, em que, o gráfico é uma curva de crescimento do tipo sigmoidal (em forma de S). Dois modelos matemáticos que apresentam esta característica são os modelos Logístico e Gompertz.

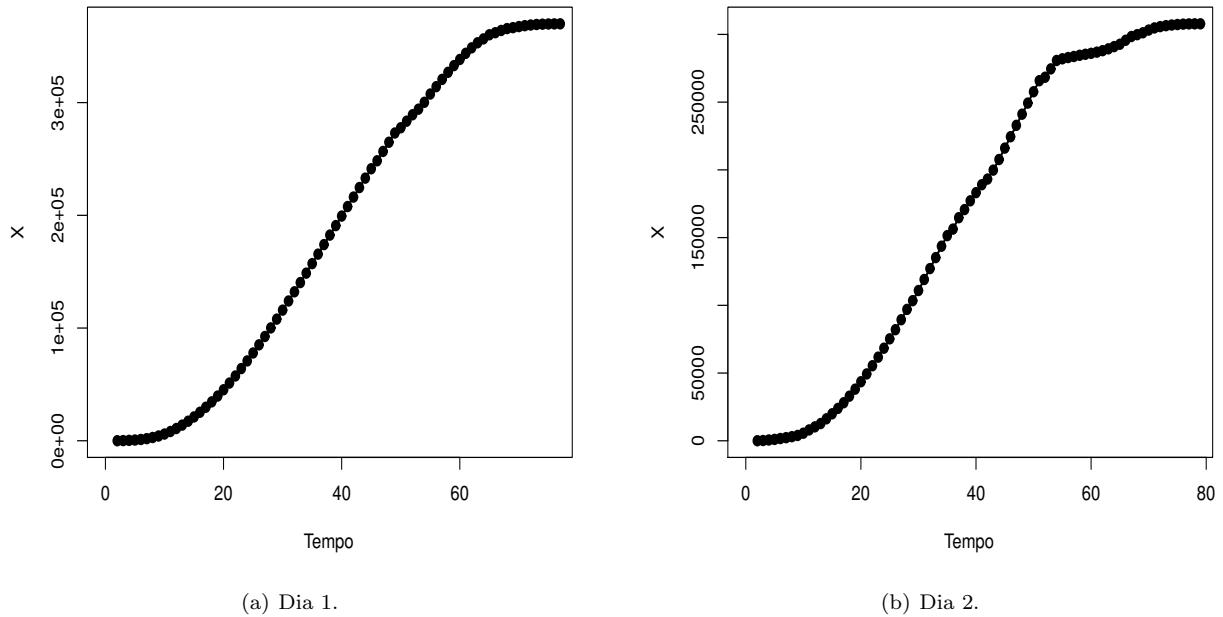


Figure 2: Potências acumuladas, dias 1 e 2.

Contudo, antes de descrevermos os modelos, considere a transformação logarítmica para os valores das potências acumuladas. Esta transformação é feita com o objetivo de obter valores em uma escala numérica que seja matematicamente e computacionalmente mais adequada para se desenvolver a modelagem e o procedimento de estimação dos parâmetros.

Assim, considere  $Y_{ij} = \log(X_{ij})$ , *i.e.*, logaritmo da potência acumulada até o  $i$ -ésimo instante do dia  $j$ , para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ . A Figura 3 mostra os gráficos da Figura 2 nas escala logarítmica.




Figure 3: Logaritmo das potências acumuladas, dias 1 e 2.

### 3.1. Modelos Log-Logístico e Log-Gompertz

Considere que os valores  $Y_{ij}$  sejam gerados de acordo com o modelo Log-Logístico de parâmetro  $\theta = (\alpha, \beta_0, \beta_1)$ , i.e.,

$$Y_{ij} = \log(\alpha) - \log(1 + \exp\{\beta_0 - \beta_1 t_{ij}\}) + \varepsilon_{ij}, \quad (1)$$

onde  $\varepsilon_{ij}$  é um erro aleatório com média 0 e variância  $\sigma^2$ , para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ . Neste modelo, o valor de  $\alpha$  representa assintota superior do modelo na escala original. Ou seja, este valor representa a estimativa para o total de potência gerada em um dia. O parâmetro  $\beta_1$  representa a taxa média de crescimento (afeta a inclinação da curva). O parâmetro  $\beta_0$  está associado as coordenadas do ponto de inflexão da curva através das expressões  $T = \frac{\beta_0}{\beta_1}$  e  $y_T = \frac{\alpha_1}{2}$ , onde  $T$  é o tempo que irá ocorrer a mudança de comportamento da curva.

**Denominamos o modelo da Equação 1 de Modelo  $ML_1$ .**

A Figura 4(a) mostra o gráfico do modelo Log-logístico para  $\alpha_1 = 10.000$ ,  $\alpha_2 = 9$  e  $\alpha_3 = \{0.20, 0.40, 0.60\}$  sem o erro aleatório  $\varepsilon_{ij}$ , para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ . A Figura 4(b) mostra o mesmo gráfico na escala original, i.e.,  $X_{i,j} = \exp\{Y_{ij}\}$ , para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ . Os símbolos  $\bullet$  nos gráficos são os pontos de inflexão.

Como podemos notar Figura 4(b) o gráfico é simétricos em relação ao ponto de inflexão das curvas. Aumentando o valor de  $\beta_1$  (taxa de crescimento) e mantendo  $\alpha$  e  $\beta_0$  fixos, mais rápido é o crescimento da curva. Além disso, note que, os gráficos da Figura 4 apresentam o formato desejado para modelagem dos dados apresentados nos gráficos das Figuras 3 e 2.

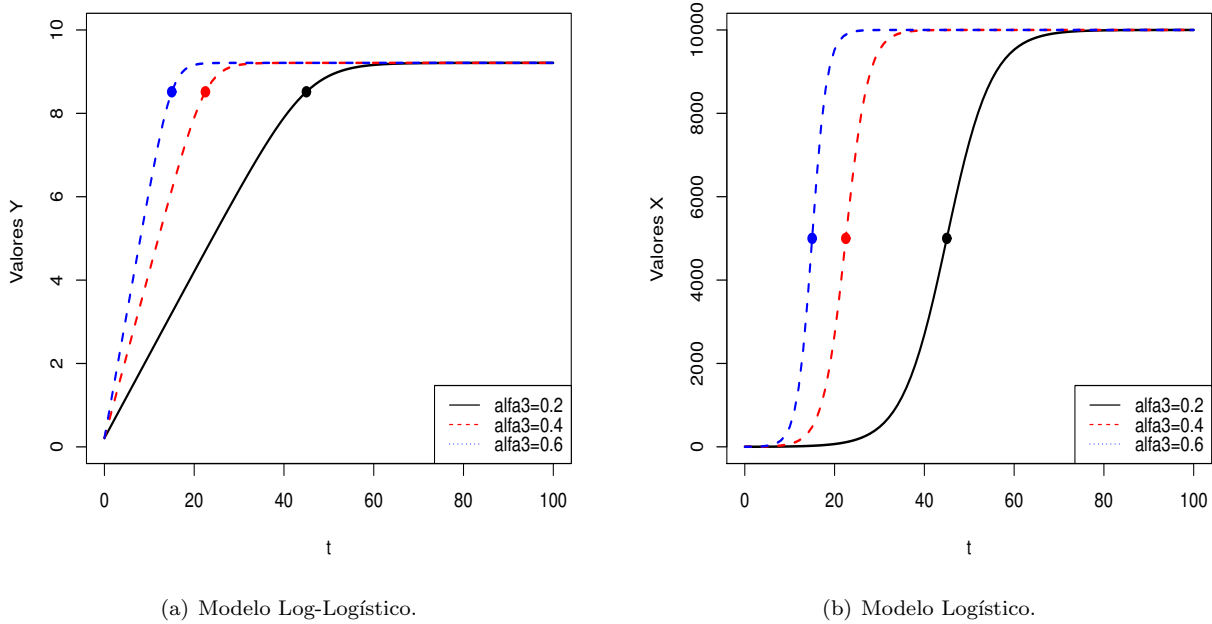


Figure 4: Gráficos dos modelos Log-logístico e Logístico.

Como segundo modelo, considere que os valores  $Y_{ij}$  sejam gerados de acordo com o modelo Log-Gompertz de parâmetro  $\theta = (\alpha, \beta_0, \beta_1)$ , i.e.,

$$Y_{ij} = \log(\alpha) - \exp\{\beta_0 - \beta_1 t_{ij}\} + \varepsilon_{ij}, \quad (2)$$

onde  $\alpha_1$ ,  $\alpha_2$  e  $\alpha_3$  são os parâmetros do modelo. De maneira similar ao modelo Logístico, no modelo Gompertz o valor do parâmetro  $\alpha$  é a assintota superior. O parâmetro  $\beta_1$  é a taxa média de crescimento e o parâmetro  $\beta_0$  determina o valor da abcissa do do ponto de inflexão através da expressão  $T = \frac{\beta_0}{\beta_1}$ . **Denominamos este modelo de  $MG_1$ .**

A Figura 5(a) mostra o gráfico do modelo Log-logístico para  $\alpha_1 = 10.000$ ,  $\alpha_2 = 2.2$  e  $\alpha_3 = \{0.05, 0.10, 0.25\}$  sem o erro aleatório  $\varepsilon_{ij}$ , para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ . A Figura 5(b) mostra o mesmo gráfico na escala original, i.e.,  $X_{i,j} = \exp\{Y_{ij}\}$ , para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ . Os símbolos  $\bullet$  nos gráficos são os pontos de inflexão. Aumentando o valor de  $\beta_1$  e mantendo  $\alpha$  e  $\beta_0$  fixos, mais rápido é o crescimento da curva.

A principal diferença entre o modelo Logístico e o modelo Gompertz é que o modelo Gompertz não é simétrico em relação ao ponto de inflexão, ver Figura 5(b). O valor da ordena do ponto de inflexão do modelo Logístico é sempre maior do que o do modelo Gompertz. No modelo Logístico o valor é igual a metade do valor  $\alpha$ ,  $\frac{\alpha}{2}$ , e no modelo Gompertz é 36,79% do valor  $\alpha$ .

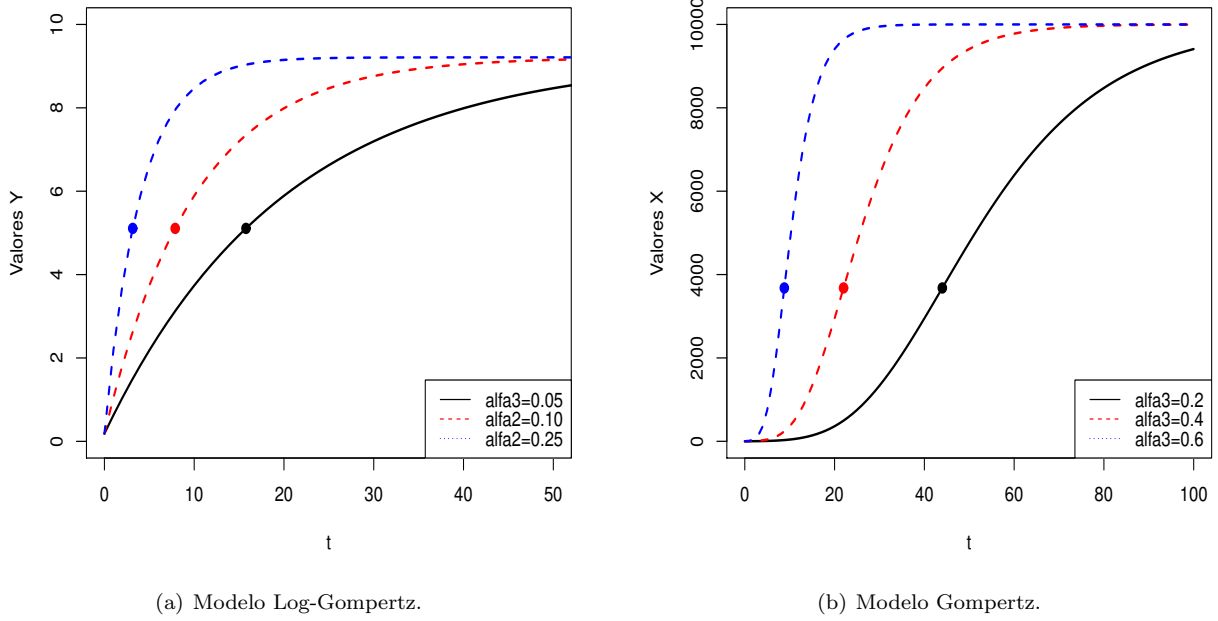


Figure 5: Gráficos dos Modelos Log-Gompertz e Gompertz.

### 3.2. Modelo Hierárquicos

Considere agora o interesse em relacionar  $Y_{ij}$  com a variável tempo ( $T$ ) e as seguintes variáveis ambientais:

$$\begin{aligned} I &= \text{Irradiancia acumulada;} \\ M &= \text{Massa acumulada de particulados.} \end{aligned}$$

Para mantermos um escala adequada para todas as variáveis, também consideramos a transformação logarítmica para os valores observados das variáveis  $I$  e  $M$ .

Utilizando o modelo Logístico dado na Equação (1), assuma a seguinte relação hierárquica entre a variável resposta  $Y$  e as variáveis explicativas

$$Y_{ij} = \log(\alpha) - \log(1 + \exp\{\beta_{ij}^* - \beta_3 T_{ij}\}) + \varepsilon_{ij} \quad (3)$$

$$\beta_{ij}^* = \beta_0 + \beta_1 I_{ij} + \beta_2 M_{ij} + u_{ij}, \quad (4)$$

onde,  $\varepsilon_{ij}$  e  $u_{ij}$  são erros aleatórios com a suposição de média igual a 0 e variâncias  $\sigma^2$  e  $\sigma_u^2$ , respectivamente. Além disso, também assumimos que  $\varepsilon_{ij}$  e  $u_{ij}$  são independentes, para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ .

Das expressões em (3) e (4), temos que

$$Y_{ij} = \log(\alpha) - \log(1 + \exp\{\beta_0 + \beta_1 I_{ij} + \beta_2 M_{ij} - \beta_3 T_{ij} + u_{ij}\}) + \varepsilon_{ij} \quad (5)$$

Denominamos este modelo de  $ML_2$ .

Como as medidas de potência gerada dentro de cada dia são feitas longitudinalmente, é plausível assumir que os erros aleatórios  $\varepsilon_{ij}$  são correlacionados. Assim, considere que  $\varepsilon_{ij}$  e  $\varepsilon_{(i+s)j}$  são dois erros do  $j$ -ésimo dia separado por  $s$  unidades de tempo. Assumindo um modelo auto-regressivo de primeira ordem ( $AR_1$ ), a correlação entre os dois erros é dada por  $\text{corr}(\varepsilon_{ij}, \varepsilon_{(i+s)j}) = \rho^{|s|}$ , para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ . Denominamos o modelo da Equação (5) com estrutura de correlação  $AR_1$  de modelo  $ML_3$ .

Considere agora o modelo Log-Gompertz dado na Equação (2) com a seguinte relação hierárquica entre a variável resposta  $Y$  e as variáveis explicativas

$$Y_{ij} = \log(\alpha) - \exp\{\beta_{ij} - \beta_3 T_{ij}\} + \varepsilon_{ij} \quad (6)$$

$$\beta_{ij}^* = \beta_0 + \beta_1 I_{ij} + \beta_2 M_{ij} + u_{ij}, \quad (7)$$

onde,  $\varepsilon_{ij}$  e  $u_{ij}$  são erros aleatórios com a suposição de média igual a 0 e variâncias  $\sigma^2$  e  $\sigma_u^2$ , respectivamente. Além disso, também assumimos que  $\varepsilon_{ij}$  e  $u_{ij}$  são independentes, para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ .

Das expressões em (6) e (7), temos que

$$Y_{ij} = \log(\alpha) - \exp\{\beta_0 + \beta_1 I_{ij} + \beta_2 M_{ij} - \beta_3 T_{ij} + u_{ij}\} + \varepsilon_{ij} \quad (8)$$

Denominamos este modelo de  $MG_2$ . Além disso, considere como modelo  $MG_3$  o modelo da expressão (8) com estrutura de correlação  $AR_1$ .

#### 4. Resultados

Para estimação dos parâmetros dos modelos  $ML_1$  e  $MG_1$  utilizamos o software R e o comando `nlme` do pacote `nlme` (Pinheiro *et al.*, 2020). Utilizando os modelos  $ML_1$  e  $MG_1$  estimados, obtemos as estimativas para os parâmetros dos modelos  $ML_2$  e  $MG_2$  utilizando o comando `update` com a opção `fixed=c(alpha ~ 1, beta0 ~ I + M, beta1 ~ 1)`, `random=(beta0 ~ 1)`. Para estimação dos parâmetros dos modelos  $ML_3$  e  $MG_3$  utilizamos os modelos  $ML_2$  e  $MG_2$  estimados e o comando `update` com a opção `autocorrelation = corCAR1`.

Comparamos os modelos ajustados, utilizando os critérios de seleção de modelos AIC e BIC. A Tabela 1 mostra os valores dos critérios de seleção de modelos para os seis modelos. O modelo com menor valor AIC e BIC é o modelo que melhor explica os dados observados. Os valores destacados em negrito são os menores valores AIC e BIC. Ou seja, de acordo com estes três critérios, o modelo  $ML_3$  é o melhor modelo dentre os seis modelos considerados.

Table 1: Estimativas para os efeitos fixos.

Modelo	$ML_1$	$ML_2$	$ML_3$	$MG_1$	$MG_2$	$MG_3$
AIC	2.096,099	-6.393,345	<b>-7.839,235</b>	-614,723	-7.004,732	-7.543,194
BIC	2.150,044	-6.355,583	<b>-7.796,079</b>	-560,778	-6.966,971	-7.500,038

A Tabela 2 mostra as estimativas para os parâmetros dos efeitos fixos do modelo  $ML_3$ . Para um nível de significância  $\nu = \{1\%, 5\%, 10\%\}$ , temos  $p\text{-valor} < \nu$ , com exceção para  $\beta_2$ . Isto indica que a variável  $M$  (massa acumulada) não é significativa. Contudo, isto era esperado pois o modelo foi ajustado utilizando medições em placas fotovoltaicas limpas. Devido a isto, optamos por manter esta variável no modelo. As estimativas para os desvios-padrão dos erros aleatórios são  $\hat{\sigma} = 0,0453$  e  $\hat{\sigma}_u = 9,4556 \cdot 10^{-6}$ . A estimativa do coeficiente de correlação é  $\hat{\rho} = 0.9778$ , indicando uma correlação forte.

Table 2: Estimativas para os efeitos fixos.


Parâmetros	Estimativa	Erro padrão	G.L.	Estatística t	p-valor
$\alpha$	14,4664	0,2662	1.602	54,3451	$< 0,0001$
$\beta_0$	12,7662	0,2682	1.602	47,6033	$< 0,0001$
$\beta_1$	-1,0791	0,0028	1.602	-372,1501	$< 0,0001$
$\beta_2$	-0,0064	0,0006	1.602	-1,0171	$< 0,3093$
$\beta_3$	-0,0037	0,0009	1.602	-4,1692	$< 0,0001$

O modelo  $ML_3$  estimado é dado por


$$\hat{Y}_{ij} = 14,4664 - \exp\{12,7662 - 1,0791I_{ij} - 0,0064M_{ij} + 0,0037t_{ij}\},$$

para  $i = 0, 1, \dots, k_j$  e  $j = 1, \dots, n$ .


A Figura 6, mostra os valores  $Y$ 's observados nos dias 1, 2, 3 e 4 (símbolos  $\bullet$ ) e o modelo  $ML_3$  ajustado (linha contínua na cor vermelha). O erro quadrático médio (EQM) para os valores destes quatro dias são 0,0036, 0,0061, 0,0040 e 0,0046, respectivamente. Para os dados dos 21 dias, o EQM é de 0,0063.




(a) Dia 1.



(b) Dia 2.



(c) Dia 3.



(d) Dia 4.

Figure 6: Gráficos dos valores observados e o valores estimados pelo modelo Log-Logístico, dias 1 à 4.

Seja  $d_{ij} = \left( \frac{y_{ij} - \hat{y}_{ij}}{y_{ij}} \right) \cdot 100$  a diferença percentual entre o valor observado  $y_{ij}$  e a projeção do modelo  $\hat{y}_{ij}$ ,

no  $i$ -ésimo instante de medição do dia  $j$ ; e  $\bar{d}_i = \frac{1}{k_k} \sum_{j=1}^{k_j} d_{ij}$  e a diferença percentual média para dia  $j$ , para  $i = 1, \dots, k_k$  e  $j = 1, \dots, n$ . Para  $\bar{d}_j < 0$ , temos uma perda percentual em relação ao esperado; e para  $\bar{d}_j > 0$ , temos um ganho percentual.

A Figura 7, mostra o gráfico em barras das diferenças percentuais médias para os 21 dias considerados para o ajuste do modelo. Note que, somente nos dia 14 e 19 ocorreram ganhos em relação aos esperado pelo modelo. Porém, o ganho foi no máximo de 0,11%. A perda em relação ao esperado pelo modelo foi inferior a 1,40%. Estes resultados mostram um satisfatório ajuste do modelo.




Figure 7: Diferença percentual média por dia.


#### 4.1. Predições

Utilizando o modelo  $ML_3$  ajustado, predizemos os valores  $Y's$  para os próximos 21 dias, *i.e.*, dia 22 (DATA) à 42 (DATA). Como ilustração, a Figura 8 mostra os valores observados nos dias 22, 23, 41 e 42 e os valores preditos pelo modelo. Os valores EQM destacados nos gráficos correspondem ao valor do erro quadrático médio.


A Figura 9 mostra o gráfico em pontos dos valores EQM dos 21 dias. A linha tracejada representa a média do EQM para os 21 dias. O EQM para os 21 dias é 0,0083.

A Figura 10 mostra o gráfico em barras para as diferenças percentuais médias por dia. Para os dias 1 à 20 houve perda percentual em relação ao valor esperado. Contudo a perda foi de no máximo 1,31% e ocorreu no dia 15. A menor perda ocorreu no dia 2 (0.20%). No dia 21 houve um pequeno ganho (0.02%) em relação ao valor esperado






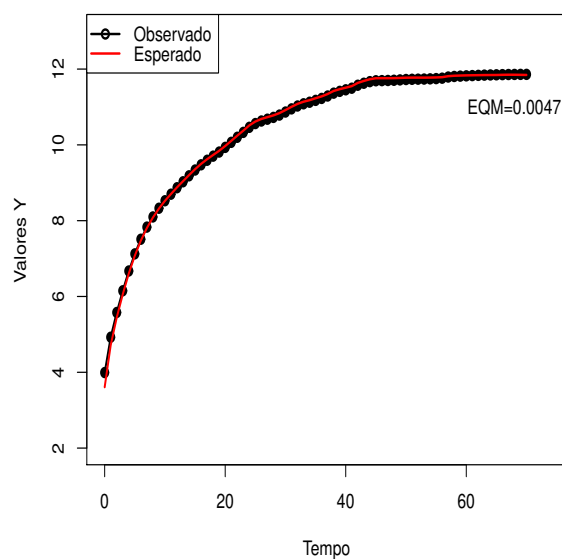
(a) Dia 22.



(b) Dia 23.



(c) Dia 41.



(d) Dia 42.

Figure 8: Gráficos dos valores observados e o valores preditos pelo modelo Log-Logístico.




Figure 9: EQM para os 21 dias




Figure 10: Diferença percentual média.

## References

- Pinheiro, J., Bates, D., DebRoy, S., Sakar, D. and R Core Team (20202). *Linear and Nonlinear Mixed*. R package version 3.1-147. URL <https://CRAN.R-project.org/package=nlme>.
- Antoniak, C. E. (1974). Mixture of processes dirichlet with applications to bayesian nonparametric problems. *The Annals of Statistics*, **2**, 1142-1174.